

UNIVERSIDAD AUSTRAL

Maestría en Ciencia de Datos (modalidad virtual)

Cohorte 2025

Análisis de Series Temporales



TRABAJO PRÁCTICO N.º 1

*Dinámica de variables ambientales de una cuenca endorreica de altura:
modelado de series de nieve, agua superficial y vegetación
en el Salar de Callacao (Puna argentina)*

Docentes: Rodrigo Del Rosso, Sebastián Calcagno, Braian Drago

Integrantes: Diego Farfán, Jaime López Garrido, Lucía Pereyra Huertas, Gabriel Martina, Analía Ale

2026

Índice de Contenido

Resumen.....	2
Introducción	3
Marco Teórico	4
Series temporales y estacionariedad	4
Transformación de la varianza y diferenciación	4
Vectores Autorregresivos y causalidad.....	7
Pronóstico	8
Análisis de Resultados	9
El caso de estudio, los datos disponibles y su control de calidad	9
Análisis exploratorio de las series.....	10
Estabilización de la varianza y determinación del orden de integración	16
Funciones de autocorrelación y pruebas de raíces unitarias	18
Estimación y selección de los modelos SARIMA	22
Evaluación, comparación de modelos y diagnóstico de residuos	24
Pronóstico univariado	28
El modelo de Vectores Autorregresivos (VAR): construcción, selección de orden y diagnóstico...	29
Causalidad de Granger, impulso-respuesta, descomposición de la varianza del error de pronóstico	31
Pronóstico multivariado y síntesis comparativa.....	33
Conclusiones	36
Limitaciones del trabajo.....	37
Líneas futuras de investigación.....	37
Referencias Bibliográficas.....	38
Apéndices	39
Apéndice A. Grilla completa de modelos SARIMA evaluados.....	39
Apéndice B. Síntesis de las decisiones metodológicas adoptadas	40

Resumen

El presente trabajo analiza la dinámica hidrológica de la cuenca endorreica del Salar de Callacao, en la Puna argentina, a partir de tres series temporales mensuales que dan cuenta, en parte, del balance hídrico del sistema: la superficie cubierta por nieve, la superficie de agua superficial y un índice de actividad fotosintética de la vegetación circundante. Estas variables constituyen proxies satelitales de una misma cadena física (nieve, deshielo, disponibilidad hídrica, respuesta vegetal) y fueron provistas por la consultora Dynamik S.A.S.

El desarrollo metodológico comprendió cuatro etapas. Primero, un análisis exploratorio y control de calidad de los datos crudos, que reveló que una de las dos exportaciones disponibles de la serie de nieve subestimaba sistemáticamente los meses de mayor nevada. Segundo, la determinación del orden de integración de cada serie mediante una batería de pruebas de raíz unitaria: la nieve resultó estacionaria en torno a un ciclo anual, mientras que el agua y la vegetación requirieron diferenciación regular, y esta última también estacional. Tercero, la estimación y comparación de modelos SARIMA univariados, evaluados fuera de muestra. Por último, un modelo de Vectores Autorregresivos sobre las tres series estacionarizadas, con el que se sometió a prueba la hipótesis de interdependencia hídrica mediante causalidad de Granger, funciones de impulso-respuesta y descomposición de varianza.

Entre los hallazgos se destaca que la relación más fuerte del sistema, entre la superficie de agua y la actividad fotosintética, es de naturaleza contemporánea y no rezagada, por lo que no se manifiesta como causalidad de Granger convencional sino como causalidad instantánea. Se identificó además un quiebre estructural en la serie de nieve hacia mediados de 2019 (un cambio de régimen a partir del cual la cantidad de nieve acumulada pasó a ser sistemáticamente menor que en las décadas previas), cuyo desconocimiento penaliza la capacidad predictiva del modelo SARIMA correspondiente. Finalmente, incorporar la dinámica conjunta de las tres series mediante un VAR mejora de forma sustancial el pronóstico de la superficie de agua respecto del modelo univariado, mientras que para la vegetación el SARIMA univariado continúa siendo preferible. El trabajo concluye que ambas familias de modelos resultan complementarias: la primera captura con precisión la forma del ciclo estacional de cada serie aislada, y la segunda permite cuantificar de qué manera un cambio en una variable del sistema se propaga sobre las restantes.

Introducción

El Salar de Callacao se ubica en la Puna argentina, a unos 4.000 metros sobre el nivel del mar en la provincia de Salta. Se trata de una cuenca endorreica (un sistema hidrológico cerrado, sin salida al mar) en la que toda el agua que ingresa permanece dentro de la cuenca hasta evaporarse o infiltrarse. La precipitación media anual es escasa y se concentra casi exclusivamente en forma de nieve durante el invierno austral, de modo que el balance hídrico de la región puede describirse como una cadena de transferencias sucesivas: la nieve acumulada en invierno se derrite en primavera y alimenta la superficie de agua disponible, que a su vez sostiene, con cierto desfase, la actividad de la vegetación de la cuenca.

Esa cadena física constituye el problema de investigación de este trabajo. Se dispone de tres series temporales mensuales que funcionan como proxies satelitales de otros tantos eslabones de dicho balance: la superficie cubierta por nieve, obtenida de imágenes Landsat entre 1986 y 2025; la superficie de agua superficial, derivada de clasificaciones de imágenes Sentinel-2 entre 2016 y 2025; y el índice de vegetación ajustado por suelo (SAVI), calculado también a partir de Sentinel-2 para el mismo período. El SAVI fue propuesto por Huete (1988) como una corrección del índice de vegetación de diferencia normalizada que incorpora un ajuste por el brillo del suelo de fondo, corrección relevante dada la costra salina intensamente reflectante de la cuenca.

El interés en analizar estas tres series de forma conjunta posee dos aristas. Desde un punto de vista predictivo, cada una exhibe un ciclo anual marcado, de modo que modelar correctamente esa estacionalidad constituye un primer objetivo en sí mismo, abordable mediante modelos autorregresivos integrados de medias móviles con componente estacional. Desde un punto de vista estructural, en un sistema hidrológico cerrado las tres variables no evolucionan de manera independiente, sino que están encadenadas por relaciones de causa y efecto que operan con determinado rezago temporal, lo cual habilita un abordaje multivariado capaz de someter esa interdependencia a prueba formal.

El objetivo general del trabajo consiste en caracterizar el comportamiento temporal de las tres series, determinar su condición de estacionariedad, ajustar modelos que permitan pronosticar su evolución futura y establecer si existe evidencia estadística de causalidad entre ellas. De ese objetivo se desprenden los siguientes objetivos específicos:

- Describir y controlar la **calidad de los datos** crudos.
- **Caracterizar la tendencia, la estacionalidad y la estacionariedad** de cada serie mediante análisis gráfico y pruebas formales de raíz unitaria.
- Estimar **modelos SARIMA** para cada serie, seleccionar la especificación más adecuada según criterios de información y significatividad estadística, y evaluar su desempeño predictivo fuera de muestra
- Construir un **modelo de Vectores Autorregresivos** sobre las tres series y analizar la causalidad de Granger, la función de impulso-respuesta y la descomposición de la varianza del error de pronóstico entre ellas.

Marco Teórico

Series temporales y estacionariedad

Una **serie temporal** es una sucesión de observaciones de una variable registradas en instantes sucesivos, en la que el orden resulta en sí mismo informativo: el valor que asume la serie en un momento dado guarda relación con los valores que asumió en el pasado (Peña, 2010). La descripción clásica la representa como la **superposición de una tendencia, un componente estacional de periodicidad fija** (habitualmente anual en datos mensuales) y **un componente irregular** (Hyndman y Athanasopoulos, 2018).

Una serie es **estacionaria en sentido débil** cuando su esperanza y su varianza son constantes en el tiempo y la covarianza entre dos observaciones depende solo de la distancia temporal que las separa (Peña, 2010). El supuesto es indispensable porque se dispone de una única realización del proceso: sin estacionariedad no hay fundamento para que promediar en el tiempo aproxime los parámetros poblacionales. Su ausencia conduce, además, a regresiones espurias entre series sin relación real que comparten una tendencia común, y a una inferencia inválida, dado que los estadísticos de contraste habituales no siguen, bajo raíz unitaria, las distribuciones que se les atribuye en el caso estacionario (Levendis, 2018).

Corresponde distinguir dos formas de no estacionariedad en la media. Una tendencia determinística se desvía de una función del tiempo pero retorna a ella tras una perturbación, de modo que los shocks son transitorios; una tendencia estocástica, en cambio, contiene una raíz unitaria: cada perturbación se incorpora de manera permanente al nivel de la serie, y la corrección adecuada es la diferenciación (Peña, 2010; Levendis, 2018). La misma distinción aplica a la estacionalidad: cuando el patrón anual se repite de manera esencialmente idéntica de un ciclo a otro es determinística; cuando se desplaza o deforma con los años existe una raíz unitaria estacional que exige diferenciación estacional (Peña, 2010).

Para detectar una tendencia monótona sin asumir una forma funcional particular (como sí lo hace la regresión lineal), puede recurrirse al estadístico **tau de Kendall**, de naturaleza no paramétrica: compara, para cada par posible de observaciones, si el orden temporal coincide con el orden de los valores, y resume esa concordancia en un número entre -1 y 1 , donde los extremos indican una tendencia perfectamente decreciente o creciente. Al no depender de la magnitud de los valores sino solo de su orden relativo, resulta más robusto frente a observaciones extremas que una regresión lineal (Levendis, 2018).

Transformación de la varianza y diferenciación

Antes de intervenir sobre la media conviene asegurar que la varianza sea razonablemente constante, dado que diferenciar una serie cuya dispersión aún depende del nivel (es decir, del valor que toma la serie en un momento dado) traslada ese problema, sin resolverlo, a la serie diferenciada (Peña, 2010). La familia de transformaciones de Box-Cox estabiliza la varianza mediante un parámetro λ que incluye como casos particulares al logaritmo ($\lambda = 0$) y a la ausencia de transformación ($\lambda = 1$) (Hyndman y Athanasopoulos, 2018). Peña (2010) recomienda contrastar el λ estimado por máxima verosimilitud con dos indicadores prácticos (la correlación entre la media y el desvío estándar por bloques de observaciones, y el coeficiente de asimetría, ambos esperables cercanos a cero tras una transformación efectiva): solo cuando el λ se aleja claramente de uno y ambos indicadores mejoran de forma neta se justifica transformar.

La **diferenciación es el instrumento estándar para convertir una serie con raíz unitaria en estacionaria**: la diferencia regular se define como $\Delta y_t = y_t - y_{t-1}$ y la estacional, de período s , como $\Delta_s y_t = y_t - y_{t-s}$ (Uriel, 1985). Un criterio operativo frecuente consiste en elegir la combinación que minimiza la varianza de la serie resultante, pero este criterio encierra una trampa: la varianza disminuye al diferenciar si y sólo si la autocorrelación de primer orden supera 0,5, exista o no una raíz unitaria genuina, por lo que su resultado debe contrastarse siempre con pruebas formales (Peña, 2010). El riesgo opuesto es la sobrediferenciación, que introduce una raíz unitaria en el componente de medias móviles y deja una autocorrelación de primer orden marcadamente negativa. La decisión sobre el orden de diferenciación debe apoyarse, por lo tanto, en más de un criterio: la evolución de la varianza ante distintos órdenes, la lectura de los correlogramas y el resultado de las pruebas de raíz unitaria.

Funciones de autocorrelación y pruebas de raíz unitaria

La **función de autocorrelación simple (FAC)** mide la correlación entre observaciones separadas por k períodos, y la **función de autocorrelación parcial (FACP)** mide esa misma relación una vez descontado el efecto de las observaciones intermedias (Peña, 2010). Cada tipo de proceso deja una huella característica: en un proceso autorregresivo puro la FAC decae de forma gradual mientras que la FACP se anula abruptamente después del rezago igual al orden del proceso, y en un proceso de medias móviles ocurre lo contrario (Box, Jenkins y Reinsel, 2008). Cuando la serie no es estacionaria, la FAC no decae hacia cero sino que permanece elevada durante muchos rezagos.

Las **pruebas de raíz unitaria** son contrastes formales sobre la necesidad de diferenciar. Se emplearon cinco. Las tres primeras comparten la hipótesis nula de raíz unitaria, aunque difieren en cómo corrigen la autocorrelación de los residuos.

- **Dickey-Fuller Aumentado (ADF)**, contrasta la hipótesis nula de raíz unitaria frente a la alternativa de estacionariedad y agrega a la regresión de contraste tantos rezagos de la variable dependiente en diferencias como resulten necesarios para que los residuos queden libres de autocorrelación (Peña, 2010; Levendis, 2018)
- **Phillips-Perron**, parte de la misma hipótesis nula, pero corrige la posible autocorrelación y heterocedasticidad de los residuos mediante un ajuste no paramétrico sobre el propio estadístico, en lugar de incorporar rezagos adicionales a la regresión.
- **Dickey-Fuller GLS (DF-GLS)** extrae primero la tendencia determinística mediante mínimos cuadrados generalizados y aplica luego el contraste sobre la serie así corregida, procedimiento que le otorga una potencia considerablemente mayor cuando la serie se encuentra cerca de la raíz unitaria sin poseerla (Levendis, 2018).
- **KPSS** invierte la lógica y postula la estacionariedad como hipótesis nula (Hyndman y Athanasopoulos, 2018), lo que permite una confirmación cruzada frente a las tres primeras.
- **Zivot-Andrews**, por último, contrasta la raíz unitaria frente a la alternativa de estacionariedad alrededor de un quiebre estructural de fecha endógena: si rechaza la hipótesis nula, la lectura correcta es que la serie resulta estacionaria alrededor de ese quiebre, y no que posea una raíz unitaria (Levendis, 2018).

Modelos SARIMA y criterios de selección

La familia de modelos ARIMA, sistematizada por Box, Jenkins y Reinsel (2008) y desarrollada por Peña (2010) y Uriel (1985), constituye el marco de referencia para modelar series estacionarias (o llevadas a la estacionariedad mediante diferenciación) a partir de su propia historia.

Un proceso autorregresivo de orden p , **AR(p)**, expresa el valor presente de la serie como combinación lineal de sus p valores pasados más un error de ruido blanco. Por otro lado, un proceso de medias móviles de orden q , **MA(q)**, lo expresa como combinación de los q errores pasados (Peña, 2010). Su combinación da lugar a un **ARMA(p,q)**, apropiado para series estacionarias.

Cuando la serie requiere d diferencias regulares para volverse estacionaria, se obtiene un **ARIMA(p,d,q)**, y cuando exhibe además estacionalidad que debe tratarse con D diferencias estacionales de período s se llega a la especificación general **SARIMA(p,d,q)(P,D,Q)_s**:

$$\phi_p(L) \Phi_P(L^s) (1 - L)^d (1 - L^s)^D Y_t = \vartheta_q(L) \Theta_Q(L^s) \varepsilon_t$$

donde L es el operador de rezago, ϕ_p y θ_q son los polinomios autorregresivo y de medias móviles regulares, y Φ_P y Θ_Q sus homólogos estacionales. Box, Jenkins y Reinsel (2008) denominaron “modelo de líneas aéreas” al caso particular SARIMA(0,1,1)(0,1,1)₁₂. Esta especificación de SARIMA se volvió referencia canónica para series mensuales con una diferencia regular y una estacional.

La identificación práctica de los órdenes p , q , P y Q se apoya en la lectura conjunta de la FAC y la FACP sobre la serie ya estacionaria: los rezagos bajos informan sobre los órdenes regulares y los múltiplos del período estacional sobre los estacionales. Dichos órdenes constituyen candidatos iniciales de un proceso iterativo de identificación, estimación y diagnóstico, y no una especificación definitiva (Box et al. 2008; Peña, 2010).

Ampliar el número de parámetros mejora habitualmente el ajuste dentro de la muestra, de modo que maximizar sin más la verosimilitud conduciría a sobreajustar. Los criterios de información resuelven este problema penalizando la cantidad de parámetros estimados (Brockwell y Davis, 2016):

- **Criterio de Información de Akaike**, $AIC = -2 \ln(\hat{L}) + 2k$, donde $\hat{L}$ es el valor máximo de la función de verosimilitud del modelo estimado y k el número de parámetros libres.
- **Criterio de Información Bayesiano**, $BIC = -2 \ln(\hat{L}) + k \cdot \ln(n)$, que penaliza con mayor severidad al sustituir la penalización constante del AIC por una que crece con el logaritmo del tamaño muestral n .

Ninguno es categóricamente superior, por lo que conviene reportar ambos y explicitar el criterio de desempate cuando no coinciden, complementando la selección con la significatividad individual de cada coeficiente (test de Wald) y la significatividad global del conjunto de términos AR/MA frente a una especificación restringida, mediante un test de razón de verosimilitudes (Peña, 2010).

Modelos de referencia: pronóstico ingenuo y suavizado exponencial

Evaluar un modelo SARIMA únicamente por sus métricas de error fuera de muestra no permite juzgar, por sí solo, si su complejidad se justifica: para eso resulta necesario contrastarlo contra alternativas más simples. En este trabajo se desarrollarán:

- El **pronóstico ingenuo estacional (seasonal naive)** es el punto de comparación más elemental posible: se limita a repetir el valor observado un período estacional atrás ($\hat{Y}_t = Y_{t-s}$), sin estimar ningún parámetro. Cuando una serie exhibe estacionalidad marcada, esta regla suele ser difícil

de superar, por lo que funciona como piso mínimo de desempeño: si un modelo más sofisticado no logra superarlo, esa complejidad adicional no se está traduciendo en mejor capacidad predictiva (Hyndman y Athanasopoulos, 2018).

- El **suavizado exponencial de Holt-Winters** constituye una alternativa de complejidad intermedia. En lugar de estimar una estructura autorregresiva explícita como el SARIMA, actualiza de forma recursiva el nivel, la tendencia y la estacionalidad de la serie mediante promedios ponderados que dan mayor peso a las observaciones más recientes. En su **variante aditiva**, el componente de tendencia puede además amortiguarse hacia el final del horizonte de pronóstico, de modo que la proyección converge hacia una pendiente cada vez más plana en lugar de continuar indefinidamente (Hyndman y Athanasopoulos, 2018).

Diagnóstico de residuos: los contrastes de Ljung-Box y de Jarque-Bera

Un modelo adecuado debe dejar residuos indistinguibles del ruido blanco. Si en los residuos permanece estructura de autocorrelación, esa estructura debería haber sido incorporada al modelo. El **contraste de Ljung-Box** evalúa precisamente esta condición, al contrastar de manera conjunta si las primeras m autocorrelaciones de los residuos son simultáneamente nulas, mediante el estadístico (Brockwell y Davis, 2016):

$$Q = n(n+2) \sum [\hat{\rho}_k^2 / (n-k)] \text{ para } k = 1, \dots, m$$

que se distribuye aproximadamente como una chi-cuadrado con grados de libertad iguales a m menos el número de parámetros estimados en el modelo (Peña, 2010). Rechazar la hipótesis nula indica que el modelo dejó estructura temporal sin capturar; no rechazarla constituye condición necesaria, aunque no suficiente por sí sola, para dar por adecuada la especificación.

El **contraste de Jarque-Bera** evalúa si la distribución de los residuos resulta compatible con la **normalidad**, al contrastar de forma conjunta el coeficiente de asimetría y el exceso de curtosis muestrales (Brockwell y Davis, 2016). La normalidad no constituye un supuesto imprescindible para la estimación por máxima verosimilitud de un modelo ARIMA, pero su ausencia condiciona la validez de los intervalos de predicción, contruidos habitualmente bajo el supuesto de errores gaussianos.

Vectores Autorregresivos y causalidad

Cuando el fenómeno de interés involucra series que se determinan de manera conjunta, un modelo univariado resulta insuficiente por definición. El **modelo de Vectores Autorregresivos** generaliza la especificación autorregresiva a un sistema de k series (Levendis, 2018):

$$Y_t = c + A_1 Y_{t-1} + \dots + A_p Y_{t-p} + \varepsilon_t$$

donde cada matriz A_i recoge el efecto de los rezagos de todas las variables sobre todas las demás. La diferencia sustantiva frente a estimar k modelos univariados por separado es que cada ecuación del sistema incluye los rezagos de las restantes variables, lo que permite contrastar si una de ellas ayuda a explicar a otra por encima de lo que su propio pasado ya explica.

El **VAR exige que las series sean estacionarias**; cuando comparten el mismo orden de integración y existe entre ellas una combinación lineal estacionaria corresponde, en cambio, un modelo de corrección de errores (Peña, 2010).

El orden p se selecciona con los mismos criterios de información del caso univariado (Akaike y Bayesiano) que pueden complementarse con otros dos:

- **Criterio de Información de Hannan-Quinn, HQIC** = $-2 \ln(\hat{L}) + 2k \cdot \ln(\ln(n))$, que penaliza la cantidad de parámetros con un término que crece más lento que el del BIC a medida que aumenta n , ubicándose en un punto intermedio entre la severidad del AIC y la del BIC.
- **Error de Predicción Final, FPE** = $\sigma^2 \cdot (n + k)/(n - k)$, donde σ^2 es la varianza residual estimada del modelo, n el tamaño muestral y k la cantidad de parámetros. A igual ajuste, castiga los modelos con más parámetros al inflar el cociente $(n+k)/(n-k)$.

El modelo estimado debe verificarse estable (todas las raíces del polinomio característico fuera del círculo unitario) para que el pronóstico y el análisis de impulso-respuesta resulten interpretables (Levendis, 2018).

La **causalidad de Granger** formaliza la idea de que una variable X causa a Y si los rezagos de X contribuyen a predecir a Y por encima de lo que ya predicen los propios rezagos de Y , lo que se contrasta mediante un estadístico F . Se trata de una noción estrictamente predictiva, no estructural, y detecta únicamente relaciones rezagadas; una asociación puramente contemporánea exige el contraste de **causalidad instantánea**, sobre la correlación de los residuos entre ecuaciones del VAR (Levendis, 2018). La **función de impulso-respuesta** traza el efecto dinámico de un shock de una desviación estándar en una variable sobre las restantes; dado que los residuos suelen estar correlacionados de manera contemporánea, aislar un shock puro exige una descomposición de Cholesky que impone un orden causal, el cual debe justificarse con fundamento externo al modelo y no afecta la significatividad de la causalidad de Granger (Levendis, 2018). La **descomposición de la varianza del error de pronóstico** cuantifica, a cada horizonte, qué proporción de esa varianza es atribuible a shocks de cada variable del sistema, incluida ella misma.

Pronóstico

Bajo un modelo correctamente especificado, el pronóstico óptimo es, en cada paso, el promedio esperado dado todo el historial disponible hasta ese momento. La incertidumbre de ese pronóstico crece cuanto más lejos en el tiempo se proyecta, lo que se traduce en intervalos de confianza cada vez más anchos a medida que avanza el horizonte.

La evaluación de la capacidad predictiva debe hacerse sobre datos que el modelo no usó para entrenarse, reservando un tramo final como **conjunto de prueba o testeo**. Entre las métricas de error se cuentan (Hyndman y Athanasopoulos, 2018):

- **Error absoluto medio (MAE)**: el promedio de las diferencias absolutas entre el valor pronosticado y el observado, expresado en las unidades originales de la serie.
- **Raíz del error cuadrático medio (RMSE)**: similar al MAE, pero al elevar los errores al cuadrado antes de promediar, penaliza con más fuerza los errores grandes
- **Error porcentual absoluto medio simétrico (sMAPE)**: expresa el error como porcentaje, dividiendo por el promedio entre el valor observado y el pronosticado en lugar de dividir solo por el valor observado (como hace su versión clásica (MAPE)), lo que evita que el error se dispare o quede indefinido cuando la serie toma valores nulos o cercanos a cero, algo frecuente en variables ambientales.

Por último, ningún modelo garantiza buen desempeño frente a cambios ocurridos después del período con el que fue entrenado: puede estar correctamente especificado y aun así generar pronósticos sesgados si el régimen vigente al momento de evaluarlo difiere del que predominó durante el entrenamiento.

Análisis de Resultados

Esta sección reconstruye el trabajo realizado sobre las tres series de interés: la preparación y el control de calidad de los datos, el análisis exploratorio, la estabilización de la varianza y la determinación del orden de integración, la estimación y comparación de los modelos SARIMA con su diagnóstico y pronóstico, y finalmente la construcción del modelo VAR con el análisis de causalidad, impulso-respuesta y descomposición de varianza que de él se deriva.

El caso de estudio, los datos disponibles y su control de calidad

El conjunto de datos comprende cuatro archivos de origen satelital referidos a la cuenca del Salar de Callacao, discriminados en siete zonas espaciales. Dos corresponden a dos exportaciones distintas de la superficie cubierta por nieve, obtenida de imágenes Landsat; el tercero contiene el índice SAVI calculado sobre imágenes Sentinel-2; y el cuarto, la superficie de agua superficial clasificada también a partir de Sentinel-2.

Antes de construir las series de trabajo fue necesario resolver dos problemas de formato: la codificación UTF-8, que antepone un carácter invisible al nombre de la primera columna de cada tabla, y la fecha del archivo de nieve, expresada en mes español abreviado (por ejemplo, “1986 ene.”), que las rutinas estándar de conversión no reconocen. Ambos se resolvieron normalizando encabezados y construyendo una tabla de correspondencia entre abreviaturas y número de mes calendario.

El control de calidad de los datos crudos arrojó tres hallazgos que condicionaron las decisiones metodológicas posteriores.

- El primero surgió al comparar las dos **exportaciones de nieve**: la segunda añadía setenta y cinco meses adicionales respecto de la primera, y correspondía a una versión depurada mediante un enmascaramiento de nubes más fino, capaz de aprovechar escenas parcialmente nubladas que la primera debía descartar. Al comparar, mes calendario por mes calendario, el valor mediano de superficie nevada entre ambas exportaciones, la mediana de los meses exclusivos de la segunda casi duplicó a la de los meses compartidos, con razones de hasta 2,5 en otoño (lectura consistente con que, en una región de altura, la nubosidad se asocia a los sistemas frontales que traen precipitación, de modo que los meses más nublados son, precisamente, los de mayor nevada). La primera exportación quedaba entonces sesgada a la baja justo en el tramo de la distribución que más importa para caracterizar el régimen nival, por lo que **se optó por trabajar con la segunda exportación de nieve para el resto del análisis**; una verificación adicional descartó, además, que el enmascaramiento estuviera introduciendo un artefacto apreciable en la serie.
- El segundo hallazgo se refiere al **archivo de SAVI**, que incluye un identificador adicional correspondiente a dos polígonos por zona medidos de manera simultánea; el **valor de cada zona se definió, en consecuencia, como el promedio de ambos polígonos**. Este archivo cubre además sólo seis de las siete zonas de la cuenca.
- El tercer hallazgo surgió al examinar la **cobertura temporal**: la nieve resultó mensual y regular entre enero de 1986 y marzo de 2025, mientras que el agua y la vegetación, de origen Sentinel-2, solo están disponibles desde julio de 2016, con muestreo irregular de entre cinco y diez días e interrupciones ocasionales de hasta cien días (Figura 1). De esta asimetría se desprendieron dos decisiones estructurales: **adoptar la frecuencia mensual como grilla común de trabajo**,

y **mantener dos ventanas de análisis**: una completa de 471 meses para el análisis univariado de la nieve, y una común de 105, entre julio de 2016 y marzo de 2025, indispensable para cualquier análisis conjunto.




Figura 1. Cobertura temporal de las tres fuentes de datos. Cada marca vertical corresponde a una fecha con observación disponible.

Para construir las tres series mensuales a partir de las siete zonas se aplicaron dos **reglas de agregación** distintas según la naturaleza física de cada variable. La superficie de nieve y la de agua son variables extensivas (su magnitud depende del área), por lo que el valor de cuenca se obtuvo **sumando** las siete zonas; el índice de vegetación es intensivo, del mismo modo que lo es una temperatura, por lo que la agregación espacial se realizó con el **promedio**. La misma distinción rigió la agregación temporal dentro de cada mes: el número de escenas satelitales disponibles varía entre dos y ocho según el mes, de modo que se utilizó el promedio y no la suma, a fin de evitar que la estacionalidad resultante reflejara en parte la frecuencia de paso del satélite y no el fenómeno físico de interés.

Tras estas agregaciones, **la serie de agua superficial presentó dos meses sin dato** dentro de la ventana común (mayo y junio de 2017), coincidentes con la interrupción de cien días detectada en el examen de cobertura (Figura 2). Por tratarse de faltantes aislados, que representan menos del 2% de las observaciones y no se ubican en los extremos de la serie, **se optó por su imputación mediante interpolación lineal**, en lugar de descartarlos o de imputarlos con un promedio global que habría introducido un salto artificial hacia el nivel medio.




Figura 2. Serie de agua superficial en la ventana común, con los dos meses imputados por interpolación lineal señalados mediante líneas verticales.

Análisis exploratorio de las series

Con las tres series mensuales ya construidas, el análisis exploratorio se orientó a **identificar tendencia, estacionalidad y heterogeneidad de la varianza** (Figura 3). Las tres exhiben un patrón estacional marcado y regular; la de nieve, en particular, muestra una asimetría muy pronunciada (coeficiente de 3,77, frente a 0,43 en la vegetación y $-0,23$ en el agua) y una dispersión que crece con el nivel, señal característica de un esquema multiplicativo que motiva más adelante la transformación logarítmica. Las tres series, además, descienden a lo largo del período común, rasgo que se cuantifica formalmente más adelante.




Figura 3. Series mensuales de nieve, actividad fotosintética (SAVI) y superficie de agua.

Perfil estacional. El perfil estacional promedio (Figura 4, Tabla 1) constituye uno de los hallazgos más relevantes: los tres máximos no coinciden en el calendario. La nieve alcanza su pico en junio, en pleno invierno austral, con un contraste superior a setenta veces respecto de su mínimo de enero; el agua superficial lo hace en mayo, desfasada respecto de la nieve; y la vegetación recién en febrero, en contrafase exacta con el ciclo de la nieve. Ese desfase sucesivo es coherente con la cadena hidrológica planteada en la introducción.




Figura 4. Distribución de cada serie por mes calendario. El panel de nieve se presenta en escala logarítmica por la amplitud del contraste entre invierno y verano.

Tabla 1. Perfil estacional promedio de las tres series en la ventana común.

Serie	Mes de máximo	Mes de mínimo	Contraste
Nieve	Junio (23 694)	Enero (326)	Superior a 70 veces
SAVI	Febrero (0,383)	Julio (0,219)	En contrafase con la nieve
Agua	Mayo (206,8)	Noviembre (124,5)	Desfasado respecto de ambas

El mapa de calor de la Figura 5, que dispone cada año en una fila y cada mes en una columna, permite evaluar si ese patrón se mantiene estable a lo largo del tiempo o se desplaza de un año a otro, lo que anticipa si la estacionalidad de cada serie será mejor descrita como determinística (y por lo tanto modelable sin diferenciación estacional) o como estocástica.




Figura 5. Mapa de calor año por mes de cada serie, utilizado para evaluar la estabilidad del patrón estacional a lo largo del tiempo.

Descomposición y fuerza de los componentes. La descomposición de cada serie (Figura 6) en tendencia, estacionalidad y residuo se realizó mediante el procedimiento STL (Seasonal and Trend decomposition using Loess), que (a diferencia de la descomposición clásica) permite que el componente estacional evolucione a lo largo del tiempo en vez de imponerle un patrón idéntico todos los años, y resulta además robusto frente a valores extremos: un atributo especialmente valioso para la serie de nieve, dada su marcada asimetría. A partir de ella se calculó la fuerza relativa de la tendencia y de la estacionalidad siguiendo a Wang, Smith y Hyndman (2006, citado en Hyndman y Athanasopoulos, 2018), que compara la varianza del residuo con la varianza de dicho residuo sumado al componente de interés (Tabla 2). El índice resultante varía entre 0 y 1: valores cercanos a 0 indican que ese componente aporta poco a la serie, y valores cercanos a 1, que domina casi por completo su comportamiento.




Figura 6. Descomposición STL de cada serie en tendencia, componente estacional y residuo.

Tabla 2. Fuerza de la tendencia y de la estacionalidad según la descomposición STL.

Serie	Fuerza de tendencia	Fuerza estacional
Nieve	0,228	0,538
SAVI	0,852	0,943
Agua	0,781	0,470

Los resultados anticiparon tres lecturas distintas. La fuerza de tendencia de la nieve resultó notablemente baja, lo que sugirió un proceso esencialmente estacionario con un ciclo estacional marcado; la vegetación presentó fuerza de tendencia y estacional muy elevadas, casi enteramente estructura, lo que anticipó la necesidad de diferenciación tanto regular como estacional; y el agua mostró un patrón intermedio, con tendencia fuerte pero estacionalidad más moderada.

Necesidad de transformar la escala de medición. El diagnóstico gráfico que enfrenta la media contra el desvío estándar de bloques anuales sucesivos (Figura 7) confirmó que únicamente en la nieve la dispersión depende claramente del nivel, relación que prácticamente desaparece en escala logarítmica: su coeficiente de variación se redujo de 2,032 a 0,232 al aplicar el logaritmo, y su asimetría cayó de 3,765 a 0,218. En vegetación y agua los mismos indicadores prácticamente no se modificaron, e incluso empeoraron levemente en el agua, cuya asimetría pasó de $-0,231$ a $-1,411$. Esta evidencia se retoma y formaliza mediante la transformación de Box-Cox en el apartado siguiente.

¿La dispersión depende del nivel? (fila 1: serie original | fila 2: log)




Figura 7. Relación entre la media y el desvío estándar por bloques anuales, en nivel y en escala logarítmica, para cada serie.

Tendencia de largo plazo. La magnitud del descenso de las tres series se cuantificó mediante una regresión lineal simple sobre el tiempo (Figura 8) y el estadístico tau de Kendall, más robusto frente a los valores extremos que abundan en la serie de nieve (Tabla 3); ambos procedimientos coincidieron en signo y significatividad.




Figura 8. Media móvil centrada de doce meses sobre cada serie, utilizada para visualizar la tendencia de fondo una vez removido el ciclo estacional

Tabla 3. Variación de nivel entre los primeros y los últimos doce meses de la ventana común, y contraste de tendencia.

Serie	Variación	Tau de Kendall	Valor p
Nieve	−91 %	−0,219	0,0009
SAVI	−36 %	−0,230	0,0005
Agua	−78 %	−0,418	< 0,0001

El agua superficial exhibió el tau más elevado, señal de un descenso consistentemente monótono, mientras que la nieve, pese a mostrar la mayor caída porcentual, presentó el tau más bajo, coherente con el peso de sus eventos extremos. Corresponde una advertencia metodológica: que una tendencia resulte significativa no permite, por sí sola, identificar su causa. En una ventana de apenas nueve años, un descenso de esta magnitud puede reflejar variabilidad climática de baja frecuencia, cambios en el procesamiento satelital o cierto grado de intervención humana; distinguir entre estas explicaciones excede lo que este conjunto de datos permite establecer. Lo que sí corresponde afirmar es que **la tendencia existe, resulta significativa, y debe incorporarse al proceso de modelado.**

Relación contemporánea y rezagada entre las series. La última pieza del análisis exploratorio consistió en examinar la asociación entre las tres series. Dado que dos series que comparten un mismo ciclo anual exhiben una correlación elevada por el solo hecho de compartir el calendario, la correlación se calculó dos veces (Figura 9): sobre las series en nivel y sobre una **versión desestacionalizada de cada una**, obtenida al sumar sus componentes de tendencia y de residuo según la descomposición STL (Tabla 4).




Figura 9. Matriz de correlación entre las tres series, calculada sobre los valores en nivel y sobre los valores desestacionalizados.

Tabla 4. Correlación contemporánea entre pares de series, en nivel y desestacionalizada.

Par de series	Correlación en nivel	Correlación desestacionalizada
Agua – SAVI	+0,39	+0,77
Nieve – Agua	+0,31	+0,38
Nieve – SAVI	-0,32	+0,12

El contraste entre ambas columnas es uno de los resultados más informativos. La asociación entre el agua y la vegetación prácticamente se duplica al desestacionalizar: al remover el ciclo compartido emerge un co-movimiento de 0,77 entre la disponibilidad de agua y la actividad fotosintética, exactamente lo que predice el balance hídrico de la cuenca. Más llamativo aún es el caso de la nieve y la vegetación, cuya correlación cambia de signo al desestacionalizar: el valor negativo observado en nivel era espurio, producto de que ambos ciclos anuales se encuentran en contrafase, y desaparece por completo una vez controlado ese efecto.

La función de correlación cruzada sobre las series desestacionalizadas (Figura 10) permitió identificar en qué rezago se ubica el pico de asociación de cada par. El pico entre agua y vegetación se ubicó en el

rezago cero, con una correlación de 0,77 que decae lentamente: se trata de una relación fundamentalmente contemporánea. El pico entre nieve y agua también se ubicó en el rezago cero, aunque más débil (0,38), apenas por encima de la banda de significatividad. El pico entre nieve y vegetación se ubicó en el rezago dos, con una correlación de 0,18 que no alcanza a superar dicha banda. Esta evidencia exploratoria sugiere un eslabón agua-vegetación fuerte pero contemporáneo y un eslabón nieve-agua débil, aunque presente; la conclusión definitiva sobre la causalidad se reserva para el modelo de Vectores Autorregresivos, dado que una función de correlación cruzada calculada sobre series aún no sometidas a pruebas de estacionariedad puede resultar engañosa.




Figura 10. Función de correlación cruzada entre pares de series desestacionalizadas, para determinar el rezago de máxima asociación.

Estabilización de la varianza y determinación del orden de integración

El orden de trabajo adoptado en esta etapa no fue arbitrario: se estabilizó primero la varianza y recién después se intervino sobre la media mediante diferenciación, siguiendo el principio de que diferenciar una serie cuya dispersión aún depende del nivel traslada ese problema a la serie diferenciada (Peña, 2010). La hipótesis reunida en el análisis exploratorio (que solo la nieve requería transformación logarítmica) se formalizó estimando el parámetro λ de Box-Cox por máxima verosimilitud para las tres series (Tabla 5).

Tabla 5. Parámetro λ de Box-Cox estimado por máxima verosimilitud para cada serie.

Serie	λ estimado	Decisión
Nieve	-0,064	$\approx 0 \rightarrow$ logaritmo
SAVI	-0,243	Cercano a 0, pero los indicadores prácticos no mejoran $\rightarrow$ sin transformar
Agua	1,062	$\approx 1 \rightarrow$ sin transformar

El resultado confirmó la necesidad de aplicar el logaritmo a la nieve: su asimetría se redujo de 3,765 a 0,218. El caso de la vegetación resultó más matizado (su λ se ubica más cerca de cero que de uno, lo que en principio sugeriría transformar), pero los indicadores prácticos (la correlación entre la media y el desvío estándar por bloques de observaciones, y el coeficiente de asimetría) apenas se modificaron al aplicarla, y el índice SAVI es, por construcción, una magnitud acotada que no presenta el problema de escala que la transformación busca resolver, por lo que se decidió no transformarla. El agua, finalmente, arrojó un λ prácticamente igual a uno, y el logaritmo deterioró su asimetría (de -0,231 a -1,411), por lo que tampoco se transformó. El criterio general adoptado fue transformar únicamente cuando el λ estimado se aleja claramente de uno y los indicadores prácticos mejoran de forma neta. La Figura 11 muestra el resultado de aplicar estas decisiones: las tres series, ya en la escala en la que se trabajó de aquí en más.




Figura 11. Series de nieve, vegetación y agua tras aplicar la transformación de varianza decidida en la Tabla 5 (nieve en escala logarítmica; vegetación y agua sin transformar).

Con la varianza ya estabilizada, se determinó el orden de diferenciación mediante el criterio de varianza mínima (Figura 12 y Tabla 6).

- El resultado de la **nieve** exige una lectura cuidadosa: dado que la varianza de una serie diferenciada disminuye si y solo si la autocorrelación de primer orden supera 0,5, y la nieve transformada presenta un valor de 0,607, apenas por encima de ese umbral, la reducción de varianza observada se explica en su totalidad por cuestión algebraica y no como evidencia de una raíz unitaria genuina (las pruebas formales del apartado siguiente lo confirman).
- Por otro lado, el caso de la **vegetación** resultó genuino: la varianza cae a menos de la octava parte de su valor original con una diferencia regular y una estacional, combinación que corresponde exactamente al modelo de líneas aéreas ($d=1$, $D=1$).
- El **agua** también resultó genuino en su componente regular (la varianza cae un 70% con una sola diferencia), pero la diferenciación estacional adicional empeora el resultado.

Criterio de varianza mínima: el punto más bajo indica el orden de integración




Figura 12. Varianza relativa a la serie sin diferenciar, según el orden de diferenciación regular y estacional aplicado, para cada serie.

Tabla 6. Combinación de diferenciación regular y estacional que minimiza la varianza, según serie (para nieve, no es la finalmente adoptada).

Serie	Combinación de mínima varianza	Razón respecto de la serie sin diferenciar
Nieve	$d = 1, D = 0$	0,781
SAVI	$d = 1, D = 1$	0,119
Agua	$d = 1, D = 0$	0,301

En función de este análisis, contrastado con las pruebas de raíz unitaria del apartado siguiente, se fijaron los órdenes de integración definitivos. Para la vegetación y el agua, estos órdenes coinciden con los sugeridos por el criterio de varianza mínima (Tabla 6), dado que en ambos casos la reducción de varianza resultó genuina. Para la nieve, en cambio, se optó por $d = 0$ y $D = 0$, apartándose de la combinación de menor varianza ($d = 1, D = 0$) que sugería la Tabla 6. Como se explicó, esa reducción se debe a un artefacto algebraico y no a una raíz unitaria real, lectura que las pruebas de raíz unitaria del apartado siguiente confirman. Los órdenes definitivos son: **nieve con $d = 0$ y $D = 0$; vegetación con $d = 1$ y $D = 1$; y agua con $d = 1$ y $D = 0$** . Estos valores constituyen el insumo directo de la especificación SARIMA.

Funciones de autocorrelación y pruebas de raíces unitarias

Antes de las pruebas formales se examinaron las funciones de autocovarianza, autocorrelación simple y parcial, tanto sobre las series ya transformadas pero sin diferenciar (Figuras 13 a 15) como, más adelante, sobre las series ya estacionarizadas (Figuras 17 a 19).

La serie de nieve exhibe un patrón oscilatorio y no de tendencia: su autocorrelación de primer orden es de 0,607, cae a $-0,395$ en el rezago seis y vuelve a subir a 0,460 en el rezago doce, alternancia que constituye la firma de un ciclo anual fuerte (con sentido físico directo, dado que junio y diciembre son el máximo y el mínimo del ciclo nival). Las series de vegetación y de agua, en cambio, inician con una autocorrelación superior a 0,83 y decaen con lentitud, firma característica de la no estacionariedad.




Figura 13. Función de autocovarianza, autocorrelación simple y autocorrelación parcial de la serie de nieve transformada, sin diferenciar.




Figura 14. Función de autocovarianza, autocorrelación simple y autocorrelación parcial de la serie de vegetación, sin diferenciar.




Figura 15. Función de autocovarianza, autocorrelación simple y autocorrelación parcial de la serie de agua, sin diferenciar.

Sobre las series sin diferenciar los correlogramas resultan dominados por la tendencia y no permiten leer todavía los órdenes autorregresivos o de medias móviles (Figuras 13 a 15); esa lectura se realiza sobre las series ya estacionarizadas, que se muestran en la Figura 16 y cuyos correlogramas se presentan en las Figuras 17 a 19.




Figura 16. Series tras aplicar la transformación de varianza y el orden de diferenciación seleccionado.

La determinación formal del orden de integración se completó con cinco pruebas de raíz unitaria, cada una bajo distintas especificaciones determinísticas ajustadas al comportamiento gráfico de cada serie (Tabla 7). Se debe contemplar que todos los tests (excepto KPSS) parten de la hipótesis nula "hay raíz unitaria". Por lo tanto, cuando rechazan significa que la serie es estacionaria. Por el contrario, para KPSS la hipótesis nula es "la serie es estacionaria", por lo tanto el rechazar significa que no es estacionaria.

- Sobre la **nieve**, las cinco pruebas bajo la especificación con tendencia resultaron coincidentes en apoyar la estacionariedad; bajo la especificación con constante sola, el KPSS y el DF-GLS discrepan, ambas discrepancias en la misma dirección: existe una deriva de nivel que la especificación con tendencia sí captura. La prueba de Zivot-Andrews detectó además un quiebre estructural en mayo de 2019 ($p = 0,0003$); al rechazar la hipótesis nula, la lectura correcta es que la serie resulta estacionaria alrededor de ese quiebre, y no que posea una raíz unitaria.
- La **vegetación**, en nivel, cayó en el cuadrante ambiguo en el que ninguna de las cinco pruebas rechaza su hipótesis nula, resultado que se interpreta como reflejo de una muestra poco informativa antes que como ausencia de estructura.
- El **agua** ofreció el diagnóstico más nítido de no estacionariedad: el ADF no rechaza mientras que el KPSS sí lo hace.

Tabla 7. Valores *p* de las pruebas de raíz unitaria sobre las series en nivel (para KPSS, rechazar equivale a concluir no estacionariedad).

Serie	ADF	Phillips-Perron	DF-GLS	KPSS	Zivot-Andrews
Nieve	0,0000 (rechaza)	0,0000 (rechaza)	0,006 c/tend. (rechaza)	0,100 c/tend. (no rechaza)	0,0003, quiebre en 2019-05
SAVI	0,927 (no rechaza)	0,228 (no rechaza)	0,339 (no rechaza)	0,075 (no rechaza)	0,967 (no rechaza)
Agua	0,967 (no rechaza)	0,131 (no rechaza)	0,711 (no rechaza)	0,010 (rechaza)	0,553 (no rechaza)

Tras diferenciar (Tabla 8):

- La **vegetación** arrojó el resultado más contundente: las cuatro pruebas con hipótesis nula de raíz unitaria rechazan con un valor *p* prácticamente nulo, y el KPSS no rechaza la estacionariedad, evidencia unánime que confirma la especificación de líneas aéreas.
- El **agua**, ya diferenciada una vez, resultó estacionaria según tres de las cuatro pruebas, con una excepción que se reporta de manera explícita: el DF-GLS no rechaza la raíz unitaria pese a ser, en principio, el de mayor potencia entre los que comparten esa hipótesis nula, lo que se atribuye a su sensibilidad a la estructura estacional residual que el correlograma ya había puesto de manifiesto en el rezago doce; la solución no consiste en diferenciar estacionalmente (descartado ya por empeorar la varianza) sino en incorporar un término estacional dentro de la especificación SARIMA.

Tabla 8. Valores *p* de las pruebas sobre las series ya diferenciadas.

Serie (diferenciada)	ADF	Phillips-Perron	DF-GLS	KPSS
SAVI (d=1, D=1)	0,0000 (rechaza)	0,0000 (rechaza)	0,0000 (rechaza)	0,100 (no rechaza)
Agua (d=1, D=0)	0,017 (rechaza)	0,0000 (rechaza)	0,430 (no rechaza)	0,100 (no rechaza)

Sobre las series ya estacionarizadas (Figuras 17 a 19), la lectura de los correlogramas resulta más informativa.

- La **vegetación** arrojó el caso más nítido: solo los rezagos uno, ocho y doce superan la banda de significatividad, y de ellos el rezago ocho carece de interpretación estructural, de modo que se descartó. La combinación de un término de medias móviles en el rezago uno y uno estacional en el rezago doce conduce directamente a la especificación SARIMA(0,1,1)(0,1,1)₁₂, que coincide exactamente con el modelo de líneas aéreas.
- La **nieve** mostró una estructura más rica: la autocorrelación parcial señaló los rezagos uno y tres entre los regulares y el rezago doce entre los estacionales, lo que sitúa los candidatos iniciales en un orden autorregresivo de uno o tres con un componente estacional de orden uno.
- El **agua** resultó la más ambigua: su autocorrelación de primer orden cayó a un valor prácticamente nulo, el primer rezago relevante apareció en el tercero, y persistió un valor de 0,261 en el rezago doce pese a no haberse aplicado diferenciación estacional, lo que sugiere estructura estacional sin capturar que deberá resolverse con un término autorregresivo o de medias móviles estacional. Estos órdenes constituyen puntos de partida para la estimación, no una especificación definitiva.




Figura 17. Función de autocovarianza, autocorrelación simple y autocorrelación parcial de la serie de nieve ya estacionaria ($d = 0$, $D = 0$).




Figura 18. Función de autocovarianza, autocorrelación simple y autocorrelación parcial de la serie de vegetación ya estacionaria ($d = 1$, $D = 1$).




Figura 19. Función de autocovarianza, autocorrelación simple y autocorrelación parcial de la serie de agua ya estacionaria ($d = 1$, $D = 0$).

Estimación y selección de los modelos SARIMA

Con los órdenes de integración fijos, se determinaron los órdenes autorregresivo y de medias móviles que completan la especificación. Antes de estimar, se reservó un tramo final de cada serie como **conjunto de prueba**: veinticuatro meses para la nieve, dado que su historia extensa permite reservar dos ciclos completos, y doce meses para la vegetación y el agua, series considerablemente más cortas (Figura 20).




Figura 20. Partición de cada serie entre el conjunto de entrenamiento y el conjunto de prueba.

Sobre el conjunto de entrenamiento se ajustó una grilla de especificaciones candidatas, acotada alrededor de los órdenes sugeridos por los correlogramas, ordenada según AIC y BIC (Tabla 9; la grilla completa se detalla en el Apéndice B).

Tabla 9. Mejor especificación SARIMA según AIC y según BIC, dentro de la grilla explorada para cada serie.

Serie	Mejor por AIC	AIC	Mejor por BIC	BIC
Nieve	$(3,0,1)(1,0,1)_{12}$	1484,36	$(2,0,1)(1,0,1)_{12}$	1510,77
SAVI	$(0,1,1)(0,1,1)_{12}$	-372,77	misma especificación	-365,62
Agua	$(1,1,1)(1,0,1)_{12}$	938,13	misma especificación	950,74

La nieve fue la única serie en la que ambos criterios discreparon, diferencia explicada por un solo parámetro autorregresivo adicional de orden tres. La decisión se resolvió a favor de la especificación de menor AIC, y no de menor BIC, porque ese coeficiente resultó individualmente significativo ($p < 0,001$): pagar el costo de un parámetro adicional se justifica cuando aporta capacidad explicativa genuina. En vegetación y agua ambos criterios coincidieron sin ambigüedad, y en la vegetación el modelo seleccionado resultó ser exactamente la especificación de líneas aéreas ya anticipada por el correlograma (confirmar el mismo resultado por dos vías independientes constituye una validación cruzada sólida de que la especificación es correcta).

Los tres modelos finalmente seleccionados son:

- **SARIMA(3,0,1)(1,0,1)₁₂ para la nieve**
- **SARIMA(0,1,1)(0,1,1)₁₂ para la vegetación**
- **SARIMA(1,1,1)(1,0,1)₁₂ para el agua**

Los tres superaron además las pruebas de significatividad individual y global. En los tres, la totalidad de los coeficientes resultó significativa al 5%; el patrón de un coeficiente de medias móviles cercano a -1 no constituye un problema de estimación sino la firma esperable de una diferenciación que remueve estructura de manera efectiva, siempre que no llegue a tocar exactamente ese valor, límite de

invertibilidad, cosa que no ocurrió en ningún caso. El test de razón de verosimilitudes contra la especificación sin términos AR/MA arrojó estadísticos de 1.649,4 para la nieve, 24,6 para la vegetación y 21,3 para el agua, en los tres casos con p muy inferior al 5%.

Evaluación, comparación de modelos y diagnóstico de residuos

Con el modelo estimado sobre el entrenamiento, se pronosticó el conjunto de prueba y se comparó contra los valores observados mediante tres métricas: el **error absoluto medio (MAE)** y la **raíz del error cuadrático medio (RMSE)**, en la escala original, y el **error porcentual absoluto medio simétrico (sMAPE)**, preferido sobre su versión clásica porque la nieve contiene meses con valores próximos a cero (Hyndman y Athanasopoulos, 2018) (Tabla 10, Figura 21).

Tabla 10. Métricas de error del pronóstico SARIMA sobre el conjunto de prueba.

Serie	MAE	RMSE	sMAPE
Nieve	2 827,73	4 069,87	118,81 %
SAVI	0,037	0,041	19,50 %
Agua	64,24	67,46	84,87 %




Figura 21. Pronóstico de cada modelo SARIMA sobre el conjunto de prueba, comparado contra el valor observado, con intervalo de confianza del 95 %.

Los resultados muestran un desempeño satisfactorio para la vegetación y razonable para el agua (cuyo error porcentual elevado se explica porque la serie transita, durante buena parte del período de prueba, valores muy próximos a cero, y no porque el ajuste sea deficiente), pero revelan un problema serio en la nieve. La causa puede asociarse a que el conjunto de prueba de la nieve, entre abril de 2023 y marzo de 2025, se ubica enteramente después del quiebre estructural de mayo de 2019, y un modelo con $d = 0$ revierte, por construcción, hacia un nivel medio estimado sobre toda la historia disponible (treinta y tres años previos al quiebre, sistemáticamente más nevados que el régimen actual). No se trata de un

modelo mal especificado, sino de una limitación del supuesto de nivel constante frente a un cambio de régimen real que el modelo no tiene forma de incorporar sin una intervención explícita.

El desempeño de cada SARIMA se contrastó, además, contra dos modelos de referencia, el **pronóstico ingenuo estacional** y el **suavizado exponencial de Holt-Winters aditivo** descritos en el Marco Teórico (Tabla 11). A este último se le incorporó componente de tendencia, amortiguada hacia el final del horizonte, únicamente en la vegetación y el agua (coherente con su orden de integración regular, $d = 1$), mientras que a la nieve no se le asignó tendencia, dado que se la había caracterizado como estacionaria alrededor de un ciclo ($d = 0$).

El SARIMA resultó preferible solo en la vegetación. En las otras dos series lo superó o igualó un modelo más simple (el ingenuo estacional en la nieve, Holt-Winters en el agua), ambas con cambio de régimen o tendencia de mayor magnitud, donde el orden de integración fijo del SARIMA impone una estructura menos capaz de adaptarse a un nivel que se desplaza.

Tabla 11. Comparación del error porcentual simétrico entre el modelo SARIMA y dos modelos de referencia.

Serie	SARIMA	Naive estacional	Holt-Winters	Modelo de mejor desempeño
Nieve	118,8 %	94,1 %	135,1 %	Naive estacional
SAVI	19,5 %	27,6 %	23,3 %	SARIMA
Agua	84,9 %	81,7 %	67,0 %	Holt-Winters

El **diagnóstico de residuos** se realizó mediante cuatro herramientas gráficas, complementadas con los contrastes formales de **Ljung-Box** y **Jarque-Bera** (Figuras 22 a 24, Tabla 12):

- **Residuos estandarizados:** permiten inspeccionar si el error de pronóstico se comporta como ruido aleatorio a lo largo del tiempo, sin patrones sistemáticos.
- **Histograma:** contrasta la forma de la distribución de los residuos contra la de una distribución normal.
- **Gráfico cuantil-cuantil:** compara los cuantiles de los residuos con los que tendría una distribución normal teórica. Los apartamientos de la diagonal, sobre todo en las colas, anticipan de forma visual lo que después confirma (o no) el contraste de Jarque-Bera. Es un chequeo relevante porque de la normalidad de los residuos depende la confiabilidad de los intervalos de confianza del pronóstico, no la calidad del ajuste en sí.
- **Correlograma de los residuos:** muestra la autocorrelación remanente en cada rezago; es el complemento visual directo del contraste de Ljung-Box, que evalúa esa misma ausencia de estructura de forma conjunta y formal.

nieve — diagnóstico de residuos




Figura 22. Diagnóstico de residuos del modelo SARIMA de la serie de nieve: residuos estandarizados, histograma frente a la densidad normal, gráfico cuantil-cuantil y correlograma de los residuos.

savi — diagnóstico de residuos




Figura 23. Diagnóstico de residuos del modelo SARIMA de la serie de vegetación.




Figura 24. Diagnóstico de residuos del modelo SARIMA de la serie de agua.

Tabla 12. Valores p del contraste de Ljung-Box en distintos rezagos y del contraste de Jarque-Bera, sobre los residuos de cada modelo SARIMA.

Serie	Ljung-Box (6)	Ljung-Box (12)	Ljung-Box (24)	Jarque-Bera	Asimetría	Curtosis
Nieve	1,00	0,99	0,99	0,00	0,57	4,14
SAVI	0,91	0,76	0,87	0,48	0,13	3,61
Agua	0,08	0,17	0,06	0,00	0,98	6,07

La condición más importante para dar por válido un modelo (que no quede estructura predecible en sus residuos) se cumplió en los tres casos: ningún valor p de Ljung-Box, evaluado en los rezagos seis, doce y veinticuatro, desciende del 5%. El contraste de Jarque-Bera, en cambio, rechaza la normalidad en la nieve y en el agua, ambas con asimetría positiva y colas más pesadas que las de una normal, resultado esperable en variables ambientales acotadas por cero y sujetas a eventos extremos. La vegetación sí superó este contraste. La falta de normalidad no invalida la estructura de los modelos, pero advierte que los intervalos de predicción de nieve y agua deben interpretarse con cautela.

Para **confirmar de manera formal que la representación estacional era necesaria** se reestimó cada modelo suprimiendo el componente estacional y se comparó el criterio de información y el correlograma de residuos en el rezago doce entre ambas versiones (Tabla 13)

En las tres series, suprimirlo empeora el AIC y deja el rezago doce con autocorrelación significativa, lo que confirma que la representación SARIMA (y no una especificación puramente regular) es la adecuada.

Tabla 13. Comparación entre cada modelo SARIMA elegido y la misma especificación sin componente estacional.

Serie	AIC con componente estacional	AIC sin componente estacional	Ljung-Box (12) con vs. sin componente estacional
Nieve	1 484,4	1 673,5	0,99 frente a 0,00
SAVI	-372,8	-356,2	0,76 frente a 0,00
Agua	938,1	946,5	0,17 frente a 0,01

Pronóstico univariado

Una vez validada cada especificación, se generó el pronóstico final reestimando cada modelo sobre la totalidad de la serie disponible, y proyectando veinticuatro meses para la nieve y doce para la vegetación y el agua (Figura 25). El pronóstico reproduce adecuadamente la forma del ciclo estacional esperado, pero exhibe dos limitaciones ya anticipadas por los resultados anteriores. En la nieve, el intervalo de confianza resulta extremadamente amplio, porque el modelo continúa ligado al promedio de treinta y nueve años de historia y no al nivel más bajo vigente desde el quiebre de 2019; el pronóstico debe interpretarse como la dinámica cíclica esperable si el proceso retomara su comportamiento histórico promedio, y no como la predicción puntual más verosímil. En el agua, el intervalo incluye valores negativos en varios meses, resultado físicamente imposible, consecuencia de combinar una serie no transformada con un modelo de errores gaussianos sin cota inferior en cero. Esto se resuelve simplemente truncando el intervalo en 0 al reportar este pronóstico.




Figura 25. Pronóstico final de cada modelo SARIMA, reestimado sobre la serie completa, con intervalo de confianza de 95%.

El modelo de Vectores Autorregresivos (VAR): construcción, selección de orden y diagnóstico

El análisis exploratorio había dejado planteada, sin resolverla de manera formal, la hipótesis de que **las tres series se encuentran vinculadas por una dinámica de interdependencia propia de un sistema hídrico cerrado**. El modelo de Vectores Autorregresivos permite estimarlas como un sistema conjunto y **contrastar esa hipótesis de manera formal**.

El VAR exige series estacionarias, condición que se satisface con las versiones ya estacionarizadas de las tres series. El estacionarizar cada serie de forma independiente tiene una consecuencia práctica: la doble diferenciación de la vegetación le hace perder trece observaciones frente a una sola del agua y ninguna de la nieve, de modo que la **intersección de las tres series ya estacionarizadas arrojó una ventana efectiva de noventa y dos meses**, entre agosto de 2017 y marzo de 2025 (Figura 26), verificada nuevamente estacionaria mediante ADF (Dickey-Fuller Aumentado) (nieve: $p = 0,0001$; SAVI y agua: $p < 0,0001$) .




Figura 26. Series estacionarias de nieve, vegetación y agua utilizadas para la estimación del modelo de Vectores Autorregresivos.

La selección del orden del VAR comparó los cuatro criterios descritos en el Marco Teórico para órdenes de hasta doce rezagos, límite elegido para dar al modelo la posibilidad de capturar el ciclo estacional de la nieve y el agua.

Tres de los cuatro criterios (Bayesiano, Hannan-Quinn y Error de Predicción Final) coincidieron en un orden igual a 1; solo el AIC sugirió un orden mayor (12) aunque por un margen mínimo y a costa de multiplicar la cantidad de parámetros a estimar con muy pocas observaciones disponibles. El segundo mínimo valor está asociado al orden 1 (Tabla 14).

Tabla 14. Selección del orden del VAR: valores de los cuatro criterios de información por rezago (el * marca el mínimo de cada columna).

Rezago	AIC	BIC	FPE	HQIC
0	0,5498	0,6391	1,733	0,5856
1	0,1518	0,5091*	1,164*	0,2950*
2	0,2809	0,9062	1,326	0,5316
3	0,3335	1,227	1,401	0,6916
4	0,3390	1,500	1,416	0,8046
5	0,4310	1,860	1,564	1,004
6	0,4343	2,131	1,587	1,115
7	0,4263	2,392	1,600	1,214
8	0,1722	2,405	1,268	1,068
9	0,1614	2,663	1,289	1,164
10	0,2220	2,991	1,419	1,332
11	0,1637	3,201	1,400	1,381
12	0,1466*	3,452	1,454	1,472

Se optó, en consecuencia, por el **orden uno**, con el mismo razonamiento de parsimonia aplicado en la selección de los SARIMA. Esta elección tiene una consecuencia importante: con un solo rezago, **el VAR no está en condiciones de reproducir el ciclo estacional de doce meses que la nieve y el agua todavía conservan**, de modo que **el modelo resultará útil para capturar la interdependencia de corto plazo entre las series, pero no sustituye a los SARIMA univariados en su capacidad de reproducir la forma del ciclo anual**.

El VAR de orden uno, estimado sobre las noventa y dos observaciones disponibles, **resultó estable**: las tres raíces del polinomio característico (de módulo 13,3; 4,4 y 1,7) se ubican fuera del círculo unitario, condición necesaria para que el pronóstico y el análisis de impulso-respuesta resulten interpretables.

El diagnóstico de sus residuos, sin embargo, arrojó una limitación esperable por la decisión sobre el orden. El contraste que evalúa si los residuos se comportan como ruido blanco (es decir, sin autocorrelación remanente), y en este caso la rechazó en el rezago doce ($p = 0,012$): contracara directa de haber optado por un único rezago sin componente estacional. El contraste de normalidad multivariada también rechazó. Ninguna de las dos limitaciones invalida el análisis de causalidad e impulso-respuesta que se desarrolla a continuación, pero sí condiciona la confiabilidad del pronóstico multivariado.

Causalidad de Granger, impulso-respuesta y descomposición de la varianza del error de pronóstico

El contraste de causalidad de Granger se ejecutó sobre las seis direcciones posibles entre pares de series (Tabla 15).

Tabla 15. Contraste de causalidad de Granger para las seis direcciones posibles entre pares de series.

Dirección	Estadístico F	Valor p	¿Causalidad de Granger?
Nieve → Agua	4,51	0,035	Sí
Nieve → SAVI	1,96	0,163	No
SAVI → Nieve	0,10	0,754	No
SAVI → Agua	1,32	0,252	No
Agua → Nieve	0,20	0,651	No
Agua → SAVI	0,23	0,634	No

De las seis direcciones examinadas, **una sola resultó significativa: la nieve causa, en el sentido de Granger, a la superficie de agua** ($p = 0,035$). Ninguna otra dirección alcanzó significatividad, incluida la relación entre agua y vegetación, que había exhibido la correlación desestacionalizada más alta de todo el análisis. Esa aparente contradicción se debe a que el contraste convencional solo detecta relaciones rezagadas, y la correlación agua-vegetación había mostrado su pico exactamente en el rezago cero. Para captar ese tipo de vínculo corresponde el contraste de causalidad instantánea (Tabla 16), que confirma lo que la matriz de correlación de residuos ya indicaba: la vegetación y el agua rechazan la ausencia de causalidad instantánea frente al resto del sistema, mientras que la nieve no lo hace.

Tabla 16. Contraste de causalidad instantánea de cada variable frente al resto del sistema.

Variable	Estadístico	Valor p	¿Causalidad instantánea?
Nieve	0,329	0,848	No
SAVI	6,407	0,041	Sí
Agua	6,354	0,042	Sí

La cadena hidrológica nieve-agua-vegetación planteada desde la introducción existe, entonces, pero no de forma homogénea: **el primer eslabón, entre nieve y agua, es débil pero rezagado y estadísticamente real; el segundo, entre agua y vegetación, es el más fuerte de todo el sistema pero de naturaleza contemporánea.**

El análisis de impulso-respuesta se calculó ortogonalizando los residuos mediante una descomposición de Cholesky, con las series ordenadas nieve, agua y vegetación, siguiendo la cadena hidrológica hipotetizada: la nieve, como variable más alejada del resto en términos de correlación de residuos, se ubicó primera, criterio recomendado por Levendis (2018) para la variable más exógena del sistema. De los seis paneles fuera de la diagonal (Figura 27), únicamente dos exhiben una banda de confianza que no incluye el cero: la respuesta del agua ante un shock en la nieve, en el período inmediato, con un intervalo entre $-14,29$ y $-0,70$; y la respuesta de la vegetación ante un shock en el agua, en el mismo período, entre $0,0017$ y $0,0117$. Ambos coinciden exactamente con los dos vínculos ya identificados

mediante los contrastes de causalidad. El resto de las combinaciones presenta bandas que incluyen ampliamente el cero en todos los periodos.




Figura 27. Función de impulso-respuesta ortogonalizada, con orden de Cholesky nieve, agua y vegetación, y bandas de confianza del 95 %.

Este resultado depende, como explica Levendis (2018), del orden de Cholesky adoptado: la ubicación de la nieve resulta poco sensible a esa elección, dado que su correlación de residuos con las otras dos variables es baja, pero el orden relativo entre agua y vegetación sí podría alterar el reparto de la respuesta contemporánea entre ambas.

La descomposición de la varianza del error de pronóstico (Figura 28, Tabla 17) complementó este análisis cuantificando qué proporción de la varianza del error de pronóstico de cada variable, a doce meses, resulta atribuible a shocks originados en cada una de las tres series.




Figura 28. Descomposición de la varianza del error de pronóstico a doce meses, para cada una de las tres series.

Tabla 17. Descomposición de la varianza del error de pronóstico a un horizonte de doce meses.

Variabl e	Explicada por sí misma	Por nieve	Por agua	Por SAVI
Nieve	99,8 %	—	0,1 %	0,1 %
Agua	93,1 %	5,4 %	—	1,5 %
SAVI	91,6 %	1,6 %	6,8 %	—

La nieve resultó prácticamente autocontenida: el 99,8% de la varianza de su error de pronóstico se explica por sus propios shocks, coherente con su rol de variable más exógena del sistema. El agua y la vegetación, en cambio, reciben una contribución apreciable aunque moderada de las restantes variables (5,4% de la varianza del agua explicado por la nieve, y 6,8% de la varianza de la vegetación explicado por el agua), en un orden de magnitud coherente con la causalidad de Granger y la causalidad instantánea ya documentadas: ninguna de las dos series queda gobernada por las restantes, pero el balance hídrico de la cuenca deja en ambas una huella real, aunque secundaria frente a su propia dinámica.

Pronóstico multivariado y síntesis comparativa

El desempeño predictivo del VAR se evaluó reservando un conjunto de prueba de doce meses, entre abril de 2024 y marzo de 2025, coincidente con el utilizado para los SARIMA de la vegetación y del agua, lo que permite una comparación directa para esas dos series (Figura 29). En la nieve, la comparación resulta solo indicativa, dado que el SARIMA correspondiente fue evaluado sobre una ventana de prueba más extensa.




Figura 29. Pronóstico del modelo VAR sobre el conjunto de prueba, comparado contra el valor observado.

La Tabla 18 compara el error de pronóstico fuera de muestra del SARIMA univariado contra el del VAR, serie por serie. El resultado más relevante de todo el análisis multivariado surge de esta comparación: el **VAR reduce el error porcentual simétrico del agua superficial de 84,9% a 58,8%**, una mejora de más de 25 puntos porcentuales, sobre exactamente la misma ventana de prueba. La explicación es directa: la nieve causa, en el sentido de Granger, al agua, de modo que un modelo que incorpora ese rezago dispone de información que el modelo univariado no puede utilizar por construcción. Se trata de la prueba empírica más concreta de que modelar el sistema de manera conjunta aporta valor predictivo real, y no solamente interpretativo.

Tabla 18. Comparación del error de pronóstico entre el modelo SARIMA univariado y el modelo VAR, sobre el mismo conjunto de prueba para SAVI y agua.

Serie	Error porcentual simétrico – SARIMA	Error porcentual simétrico – VAR	Modelo preferido
Nieve	118,8 %	114,2 %	Comparable, no estrictamente equivalente
SAVI	19,5 %	22,2 %	SARIMA
Agua	84,9 %	58,8 %	VAR

En la vegetación, en cambio, el SARIMA univariado continuó siendo preferible, aunque por un margen más moderado: el vínculo más fuerte de la vegetación con el resto del sistema (su relación con el agua) es contemporáneo y no rezagado, y un pronóstico a varios pasos no puede explotar una relación con una variable que, al momento de generar la predicción, todavía no ha sido observada. En la nieve, finalmente, ambos enfoques exhibieron un desempeño pobre y de magnitud similar, aunque no estrictamente comparable por la diferencia en las ventanas de evaluación; ambos resultados remiten al mismo problema de fondo, el quiebre estructural de 2019 no incorporado explícitamente en ninguno de los dos modelos.

El pronóstico final del VAR (Figura 30), reestimado sobre las noventa y dos observaciones completas, ofrece un matiz interesante respecto del pronóstico SARIMA de la **nieve**: como el VAR se ajustó únicamente sobre la ventana común, que comienza en 2017, su noción de nivel de referencia corresponde ya al régimen posterior al quiebre de 2019, y converge hacia un nivel considerablemente más bajo y acorde con lo observado en los últimos años, sin el intervalo de confianza desmesurado del modelo univariado. Esa ventaja tiene, sin embargo, un costo: al tratarse de un modelo de un único rezago sin componente estacional explícito, ni la nieve ni el agua reproducen en este pronóstico la forma de su ciclo anual.




Figura 30. Pronóstico final del modelo VAR a doce meses, reestimado sobre la totalidad de la ventana común estacionaria.

Los modelos SARIMA y el VAR resultan, en definitiva, complementarios y no sustitutos entre sí: el primero resulta preferible para pronosticar la forma del ciclo estacional de una serie considerada de manera aislada; el segundo, para capturar de qué manera un shock en una serie se propaga hacia las restantes, y puede mejorar de manera apreciable el pronóstico de una serie específica cuando existe una relación causal rezagada real, como la que vincula a la nieve con el agua.

Conclusiones

El objetivo general de este trabajo consistió en caracterizar el comportamiento temporal de tres series que representan eslabones del balance hídrico de una cuenca endorreica de altura, determinar su condición de estacionariedad, ajustar modelos que permitieran pronosticar su evolución futura y establecer si existía evidencia estadística de causalidad entre ellas.

El **control de calidad de los datos** crudos produjo hallazgos sustantivos que condicionaron buena parte de las decisiones posteriores. La constatación de que una de las dos exportaciones de la serie de nieve subestimaba sistemáticamente los meses de mayor nevada (por descartar precisamente los meses más nublados y, con ellos, los de mayor precipitación) muestra un sesgo que ninguna prueba estadística posterior habría podido detectar sin indagar en el origen de los datos. Del mismo modo, distinguir la agregación por suma o por promedio según la naturaleza extensiva o intensiva de cada variable evitó introducir una estacionalidad espuria que habría contaminado todo el análisis sin generar ninguna señal de error explícita.

En cuanto a la **caracterización de cada serie**, el trabajo estableció que la nieve constituye un proceso estacionario alrededor de un ciclo anual marcado, sin necesidad de diferenciación regular, mientras que la vegetación requiere tanto diferenciación regular como estacional (su especificación coincide, de hecho, con el modelo de líneas aéreas clásico de Box-Jenkins), y el agua requiere únicamente diferenciación regular. Estos resultados surgieron de la convergencia entre el criterio de varianza mínima, la lectura de los correlogramas y un conjunto de cinco pruebas de raíz unitaria, convergencia indispensable precisamente porque el criterio de varianza, aplicado de manera aislada, habría recomendado diferenciar también la nieve por una razón que resultó ser, tras el contraste formal, un artefacto puramente algebraico.

Los **modelos SARIMA** estimados resultaron estadísticamente adecuados en los tres casos, con parámetros significativos y residuos sin autocorrelación remanente. Sin embargo, la evaluación con el conjunto de testeo reveló que la adecuación estadística dentro del conjunto de entrenamiento no garantiza, por sí sola, buen desempeño predictivo: el modelo de la nieve, el mejor especificado en términos estrictamente estadísticos, fue superado por un pronóstico ingenuo al evaluarse sobre un tramo posterior a un quiebre estructural que el modelo no tiene manera de incorporar. Esta disociación entre bondad de ajuste y capacidad de generalización constituye, posiblemente, la lección más general del trabajo, aplicable más allá de este caso puntual.

El **modelo de Vectores Autorregresivos** permitió cerrar un interrogante que el análisis exploratorio había dejado abierto: la asociación más fuerte del sistema, entre el agua y la vegetación, no se manifiesta como causalidad de Granger convencional sino como causalidad instantánea, contemporánea y no rezagada. La única relación causal rezagada estadísticamente significativa resultó ser la que vincula a la nieve con el agua, más débil en magnitud pero suficientemente real como para mejorar de manera apreciable el pronóstico del agua (una reducción superior a 25 puntos porcentuales en el error de pronóstico) frente al modelo univariado correspondiente.

La respuesta a qué familia de modelos resultó más adecuada no es unívoca: el **SARIMA resultó preferible para la vegetación**, cuyo vínculo más fuerte es contemporáneo y por lo tanto inaprovechable en un pronóstico a varios pasos; el **VAR resultó preferible para el agua**, en virtud de la relación causal rezagada que la nieve ejerce sobre ella; y **para la nieve, ninguno de los dos enfoques logró un desempeño satisfactorio fuera del conjunto de entrenamiento**. La conclusión general es que **ambas familias resultan complementarias**: la primera es más apta para capturar la forma del ciclo estacional

de una serie aislada, y la segunda para cuantificar de qué manera un cambio en una variable del sistema se propaga sobre las restantes.

Limitaciones del trabajo

- Ninguna de las cinco pruebas de raíz unitaria está diseñada para detectar raíces unitarias de naturaleza estacional; la decisión sobre el orden de diferenciación estacional de cada serie se apoyó, en cambio, en el criterio de varianza mínima y en la inspección de los correlogramas.
- El **quiebre estructural** identificado en la nieve no fue incorporado de manera explícita a ningún modelo, de modo que su costo sobre la capacidad predictiva permanece sin resolver dentro de estos límites.
- La falta de normalidad en los residuos de nieve y agua advierte que sus intervalos de confianza deben interpretarse como una aproximación.
- No se propagó la incertidumbre del pronóstico del VAR a la escala original, por lo que se reportó de manera puntual (a diferencia del SARIMA, donde sí se muestran los intervalos de confianza en los gráficos).

Líneas futuras de investigación

- Incorporar una variable indicadora del quiebre estructural de la nieve dentro de una especificación SARIMAX, o alternativamente reestimar el modelo de la variable individual sobre una ventana posterior al quiebre: existe evidencia directa (el desempeño del SARIMA actual contra el pronóstico ingenuo) de que ignorar ese quiebre tiene un costo medible sobre la capacidad predictiva.
- La incorporación de una serie de temperatura aportaría una variable exógena que probablemente contribuya a explicar tanto la acumulación de nieve como su deshielo.
- La propagación de la incertidumbre del pronóstico del VAR mediante técnicas de remuestreo permitiría dotarlo de intervalos de confianza comparables a los ya reportados para los modelos univariados.
- Incorporar radar de apertura sintética (Sentinel-1, banda C) permitiría construir las series temporales de agua y nieve sin depender de las ventanas libres de nubes. Este tipo de sensor evitaría la imputación de datos faltantes y el sesgo del enmascaramiento de píxeles.

En síntesis, este trabajo mostró que una cuenca endorreica de altura, pese a la aparente simplicidad de su balance hídrico, exhibe una dinámica temporal considerablemente más matizada de lo que una lectura superficial de sus tres eslabones podría sugerir: series con distinta necesidad de diferenciación, un quiebre estructural que penaliza al modelo aparentemente mejor especificado, y una cadena causal que se manifiesta de forma heterogénea, combinando un vínculo débil pero rezagado con otro fuerte pero estrictamente contemporáneo.

Referencias Bibliográficas

- Box, G. E. P., Jenkins, G. M., & Reinsel, G. C. (2008). Time series analysis: Forecasting and control (4.^a ed.). John Wiley & Sons.
- Brockwell, P. J., & Davis, R. A. (2016). Introduction to time series and forecasting (3.^a ed.). Springer. <https://doi.org/10.1007/978-3-319-29854-2>
- Huete, A. R. (1988). A soil-adjusted vegetation index (SAVI). Remote Sensing of Environment, 25(3), 295-309. [https://doi.org/10.1016/0034-4257\(88\)90106-X](https://doi.org/10.1016/0034-4257(88)90106-X)
- Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: Principles and practice (2.^a ed.). OTexts. <https://otexts.com/fpp2/>
- Levendis, J. D. (2018). Time series econometrics: Learning through replication. Springer. <https://doi.org/10.1007/978-3-319-98282-3>
- Peña, D. (2010). Análisis de series temporales. Alianza Editorial.
- Uriel, E. (1985). Análisis de series temporales: Modelos ARIMA. Paraninfo.

Apéndices

Apéndice A. Grilla completa de modelos SARIMA evaluados

Se reproducen, para cada serie, las seis especificaciones de mejor desempeño según el Criterio de Información de Akaike dentro de la grilla explorada en la etapa de estimación, complementando la especificación finalmente seleccionada que se presentó en el cuerpo del informe.

Tabla 19. Serie nieve: seis mejores especificaciones SARIMA($p,0,q$)($P,0,Q$)₁₂ según AIC.

Orden (p,q,P,Q)	AIC	BIC	N.º de parámetros
(3,1,1,1)	1 484,36	1 513,08	7
(2,1,1,1)	1 486,15	1 510,77	6
(3,2,1,1)	1 487,32	1 520,15	8
(2,2,1,1)	1 487,79	1 516,51	7
(1,2,1,1)	1 500,58	1 525,19	6
(1,1,1,1)	1 505,30	1 525,81	5

Tabla 20. Serie SAVI: seis mejores especificaciones SARIMA($p,1,q$)($P,1,Q$)₁₂ según AIC.

Orden (p,q,P,Q)	AIC	BIC	N.º de parámetros
(0,1,0,1)	-372,77	-365,62	3
(1,0,0,1)	-371,66	-364,51	3
(0,2,0,1)	-371,11	-361,58	4
(0,1,1,1)	-371,05	-361,52	4
(1,1,0,1)	-370,98	-361,45	4
(2,0,0,1)	-370,93	-361,40	4

Tabla 21. Serie agua: seis mejores especificaciones SARIMA($p,1,q$)($P,0,Q$)₁₂ según AIC.

Orden (p,q,P,Q)	AIC	BIC	N.º de parámetros
(1,1,1,1)	938,13	950,74	5
(2,1,1,1)	939,74	954,87	6
(1,2,1,1)	939,87	954,996	6
(3,1,1,1)	939,87	957,52	7
(2,2,1,1)	940,82	958,48	7
(1,1,1,0)	941,22	951,30	4

Apéndice B. Síntesis de las decisiones metodológicas adoptadas

La Tabla 22 reúne, a modo de referencia, las decisiones metodológicas más relevantes adoptadas a lo largo del trabajo, con su justificación resumida, complementando la argumentación desarrollada en el Análisis de Resultados.

Tabla 22. Síntesis de las decisiones metodológicas más relevantes adoptadas a lo largo del trabajo.

N.º	Decisión	Justificación
1	Usar la exportación depurada de la serie de nieve	Corrige un sesgo a la baja de aproximadamente el doble en los meses de mayor nevada
2	Promediar los dos polígonos por zona en SAVI	El identificador adicional corresponde a unidades espaciales, no a observaciones repetidas
3	Suma para variables extensivas, promedio para intensivas	Distinción física entre superficies (nieve, agua) e índices (SAVI)
4	Frecuencia mensual como grilla de trabajo	Única frecuencia común a las tres fuentes de datos
5	Agregación intramensual por promedio	El número de escenas satelitales por mes no es constante
6	Interpolación lineal de los dos faltantes en agua	Faltantes aislados, menos del 2 % de la ventana común
7	Transformar solo la serie de nieve (logaritmo)	λ de Box-Cox próximo a cero; mejora sensible de la asimetría
8	Nieve: $d = 0$ pese al criterio de varianza mínima	La autocorrelación de primer orden apenas supera 0,5: artefacto algebraico
9	Elegir el SARIMA de menor AIC para la nieve, no el de menor BIC	El parámetro adicional es individualmente significativo
10	Reportar la discrepancia del DF-GLS en la serie de agua	Es la prueba de mayor potencia y no debe omitirse su resultado
11	Estacionarizar cada serie por separado en el VAR, no un VECM	Las tres series tienen distinto orden de integración
12	Orden del VAR igual a uno pese al mínimo secundario del AIC en doce	Tres de cuatro criterios coinciden en uno; el AIC en doce implica sobreajuste
13	Orden de Cholesky nieve, agua, vegetación para la IRF	Sigue la cadena hidrológica hipotetizada; la nieve es poco sensible al orden